What are the state-of-the-art approaches for Multimodal Aspect-Based Sentiment Analysis (MABSA) combining text and images in 2020–2025? Provide 5 papers and summarize: fusion strategy (cross-attention / multimodal transformer / GCN), visual encoder (CNN/ViT/CLIP), datasets, metrics, and limitations.

Pendekatan mutakhir MABSA 2020–2025 (teks+gambar)

Fokus utama: arsitektur *Transformer multimodal* dengan berbagai strategi *fusion* (cross-attention, gating, GCN/graph, dan "image-to-text"), memakai CNN/region features sebagai visual encoder; ViT/CLIP mulai muncul tapi belum dominan di makalah ini.

Ringkasan 5 paper kunci

Paper (tahun)	Strategi fusion utama	Visual encoder	Dataset & tugas	Metrik	Keterbatasan	Citations
CMMT – Cross-Modal Multitask Transformer (Yang et al., 2022, IPM)	*Text-Guided Cross-Modal Interaction Module* berbasis **multimodal Transformer**; auxiliary tasks untuk belajar representasi aspek/sentiment-aware dan mengontrol kontribusi visual per token (Yang et al., 2022)	CNN / region features (tipikal ResNet/Faster-RCNN; teks dan gambar di-encode terpisah lalu di-Transform) (Yang et al., 2022)	End-to-End MABSA (JMASA) pada **3 dataset Twitter**; joint extraction aspek + sentimen (Yang et al., 2022)	F1 AE & SC; CMMT mengungguli JML +3.1–4.1 poin absolut (Yang et al., 2022)	Bergantung pada CNN konvensional; alignment masih kasar (region-level), belum pakai ViT/CLIP; hanya bahasa Inggris & domain Twitter (Yang et al., 2022)	
AoM – Aspect-oriented Method (Zhou et al., 2023)	*Aspect-aware attention* untuk memilih token & image blocks relevan; **GCN** untuk interaksi vision-text dan text-text, fokus menghilangkan *visual/textual noise* (Zhou et al., 2023)	Region features CNN (mis. Faster-RCNN) yang dihubungkan ke node graf; aspek memandu pemilihan blok gambar (Zhou et al., 2023)	Joint MABSA (MATE+MASC) pada benchmark Twitter (JMASA) (Zhou et al., 2023)	F1 untuk MABSA/MATE/MASC; AoM mengungguli metode perhatian/korelasi sebelumnya (Zhou et al., 2023)	Mengandalkan detektor objek + anotasi region; skala data terbatas; masih lemah untuk aspek implisit dan kasus gambar-tak-relevan ekstrem (Zhou et al., 2023)	
SAAF – Self-adaptive Attention Fusion (JMABSA) (Wang & Guo, 2024, MBE)	**Generative BART** + *self-adaptive cross-modal attention*: modul *visual-to-textual fusion* yang selektif mentransfer info gambar ke ruang teks; arsitektur *multimodal Transformer* generatif (Wang & Guo, 2024)	CNN/region encoder terpisah, lalu fitur visual di-fuse ke BART (tidak ViT/CLIP) (Wang & Guo, 2024)	Joint MABSA (JMABSA) pada **2 dataset benchmark**; sekaligus MATE & MASC (Wang & Guo, 2024)	F1 untuk JMASA, MATE, MASC; mengungguli VLP-MABSA dan JML dengan margin signifikan (Wang & Guo, 2024)	Bergantung pada BART berbasis teks; kesenjangan semantik teks-gambar masih ada; biaya komputasi tinggi untuk generative Transformer (Wang & Guo, 2024)	
MTVAF – Multi-level Textual-Visual Alignment and Fusion Network (Li et al., 2024, AI Review)	Mengubah multi-level info visual (deskripsi gambar, deskripsi wajah, OCR) menjadi teks dan **menggabungkannya sebagai prompt**; *dynamic attention/visual prompts* sebagai kontrol fusion dalam sebuah text-centric Transformer (Li et al., 2024)	Visual → caption/face/OCR generator (CNN+detector) lalu direpresentasikan di ruang teks; inti pemroses adalah encoder teks terpadu (Li et al., 2024)	Joint MABSA (JMASA) di **2 dataset benchmark**; memodelkan alignment multi-granularitas (Li et al., 2024)	Accuracy/F1; melampaui SoTA sebelumnya pada dua dataset (Li et al., 2024)	Tergantung alat eksternal (captioning, face, OCR); error rantai (pipeline) dan biaya inference tinggi; belum memanfaatkan ViT/CLIP end-to-end (Li et al., 2024)	
EKMG – External Knowledge & Multi-Granularity Features (Liu et al., 2025, NPL)	*Graph Attention Network* + **cross-modal fusion** multi-granular: text & image node-level alignment, lalu contrastive learning	CNN-based vision encoder (komputer visi klasik) untuk region/patch; external knowledge digabung pada level fitur (Liu et al., 2025)	MABSA (MATE+MASC atau JMASA) pada **2 dataset publik**; fokus multi-granular alignment dan	Accuracy/F1; "significant improvements" dibanding baseline cross-attention/Transformer lain (Liu et al., 2025)	Masih di domain sosial media terbatas; external KB mungkin tak lengkap/ber-bias; *graph+contrastive* relatif mahal secara	

Paper (tahun)	Strategi fusion utama	Visual encoder	Dataset & tugas	Metrik	Keterbatasan	Citations
	untuk semantik bersama (Liu et al., 2025)		external knowledge (Liu et al., 2025)		komputasi (Liu et al., 2025)	

FIGURE 1 Perbandingan singkat 5 pendekatan MABSA mutakhir.

Pola umum pendekatan mutakhir

1. Strategi fusion

- **Multimodal Transformer / cross-attention**
  - CMMT mempelopori *Cross-Modal Multitask Transformer* dengan modul interaksi yang mengontrol kontribusi visual per kata/aspek, meningkatkan joint extraction di tiga dataset Twitter (Yang et al., 2022).
  - SAAF memperluas ke model generatif BART, memakai *self-adaptive cross-modal attention* agar visual hanya berkontribusi ketika membantu prediksi aspek/sentimen (Wang & Guo, 2024).
  - MTVAF menggunakan *dynamic attention/visual prompts* pada encoder teks: visual yang telah "diterjemahkan ke teks" diinjeksikan sebagai prompt, lalu di-align distribusi probabilitas antara ruang teks dan ruang teks+visual (Li et al., 2024).
- **GCN / GAT & graph-based fusion**
  - AoM membangun *graph* yang menghubungkan token dan region gambar, lalu GCN untuk menyebarkan informasi semantik dan sentimen, selagi aspek-aware attention menyaring node relevan (Zhou et al., 2023).
  - EKMG menggunakan *Graph Attention Network* untuk alignment multi-granular antara node teks dan gambar, ditambah contrastive learning multi-granular untuk memperkecil gap semantik (Liu et al., 2025).
- **Selective gating / noise control**
  - CMMT dan SAAF memasukkan mekanisme untuk mengatur berapa banyak informasi visual digunakan untuk tiap kata/aspek (Yang et al., 2022; Wang & Guo, 2024).
  - AoM dan EKMG fokus eksplisit pada *visual noise* dengan pemilihan region yang relevan dan pembobotan node graf (Zhou et al., 2023; Liu et al., 2025).
  - MTVAF mengontrol fusion lewat *visual prompts* dan penyelarasan distribusi output agar visual tidak merusak prediksi berbasis teks (Li et al., 2024).

2. Visual encoder

- Semua paper di atas masih bertumpu pada **CNN/region features** (ResNet/Faster-RCNN atau model visi klasik) untuk ekstraksi fitur gambar sebelum cross-attention/graph/prompting (Yang et al., 2022; Zhou et al., 2023; Wang & Guo, 2024; Li et al., 2024; Liu et al., 2025).
- Pola baru "**image-to-text**" muncul di MTVAF (caption, wajah, OCR → teks) dan juga ditekankan sebagai tren penting di survei MABSA (mis. CapBERT, EF-CapTrBERT, FITE, VLP-MABSA) (Xiao et al., 2025; Zhao et al., 2024).
- Penggunaan eksplisit ViT/CLIP tidak dilaporkan dalam lima makalah ini; CLIP-style alignment lebih banyak muncul sebagai inspirasi untuk *contrastive learning* (EKMG) daripada memakai CLIP langsung (Liu et al., 2025; Zhao et al., 2024).

3. Dataset & metrik

- **Dataset utama**:
  - Twitter-2015, Twitter-2017 dan dataset JMASA (variannya JML, MAF, dll.) dipakai secara luas di CMMT, AoM, SAAF, MTVAF, dan EKMG (Yang et al., 2022; Zhou et al., 2023; Wang & Guo, 2024; Li et al., 2024; Liu et al., 2025; Zhao et al., 2024).
  - MASAD (38k pasangan teks-gambar, 7 domain, 57 kategori aspek) menjadi sumber data besar namun lebih sering untuk MASC daripada JMASA penuh (Zhou et al., 2021; Zhao et al., 2024).
- **Metrik**:
  - *Joint MABSA / JMASA*: Precision, Recall, dan khususnya **F1** untuk pasangan aspek-sentimen (Yang et al., 2022; Zhou et al., 2023; Wang & Guo, 2024; Li et al., 2024; Liu et al., 2025).
  - MATE/AE saja: F1 span/sequence (Yang et al., 2022; Zhou et al., 2023; Wang & Guo, 2024; Liu et al., 2025).
  - MASC saja: **Accuracy** + macro-F1 (Li et al., 2024; Liu et al., 2025; Zhao et al., 2024).

4. Keterbatasan riset 2020–2025

- **Encoder visual konservatif**: Mayoritas masih memakai CNN/region features; integrasi **ViT/CLIP full** untuk MABSA hampir belum dieksplor secara sistematis dalam makalah-makalah ini (Yang et al., 2022; Zhou et al., 2023; Wang & Guo, 2024; Li et al., 2024; Liu et al., 2025; Zhao et al., 2024).
- **Ketergantungan domain & bahasa**: Hampir semua model dievaluasi pada **Twitter berbahasa Inggris**; generalisasi ke platform lain, bahasa non-Inggris, dan domain profesional (kesehatan, finansial) belum jelas (Yang et al., 2022; Zhou et al., 2023; Wang & Guo, 2024; Li et al., 2024; Liu et al., 2025; Zhao et al., 2024).
- **Keterbatasan tugas**: Banyak yang fokus pada **joint extraction + klasifikasi** (JMASA), tetapi:
  - Aspek implisit dan kategori tingkat konsep kurang tersentuh.
  - Sedikit studi pada reasoning kausal atau penjelasan (kecuali kerangka kognitif seperti Chimera untuk MASC saja (Xiao et al., 2025)).
- **Biaya & kompleksitas**:
  - Arsitektur gabungan (Transformer + GCN + contrastive learning + external knowledge) meningkatkan performa namun mahal secara komputasi dan sulit di-deploy real-time (Li et al., 2024; Liu et al., 2025; Wang & Guo, 2024).
  - Pendekatan berbasis caption/OCR/face (MTVAF) bergantung pada pipeline eksternal yang rentan error propagasi (Li et al., 2024).
- **Robustness & noise**: Meski banyak model merancang modul *noise reduction*, evaluasi terhadap kasus gambar benar-benar tak relevan, sarkasme, atau multi-modal conflict (teks positif, gambar negatif) masih terbatas (Zhou et al., 2023; Zhao et al., 2024; Yang et al., 2022; Wang & Guo, 2024).

Secara praktis, SoTA 2020–2025 untuk MABSA adalah kombinasi **PLM teks (BERT/BART) + encoder visual CNN/region + cross-modal Transformer/GCN dengan mekanisme selektif/gating**, dengan tren baru ke arah *image-to-text prompting* dan contrastive learning.

These search results were found and analyzed using Consensus, an AI-powered search engine for research. Try it at https://consensus.app. © 2026 Consensus NLP, Inc. Personal, non-commercial use only; redistribution requires copyright holders' consent.

References

Li, Y., Ding, H., Lin, Y.-M., Feng, X., & Chang, L. (2024). Multi-level textual-visual alignment and fusion network for multimodal aspect-based sentiment analysis. *Artificial Intelligence Review, 57*. https://doi.org/10.1007/s10462-023-10685-z

Liu, Z., Lin, J.-L., Chen, Y.-Z., & Dong, Y. (2025). Multimodal Aspect-Based Sentiment Analysis with External Knowledge and Multi-granularity Image-Text Features. *Neural Processing Letters, 57*. https://doi.org/10.1007/s11063-025-11737-x

Wang, Z.-Y., & Guo, J. (2024). Self-adaptive attention fusion for multimodal aspect-based sentiment analysis.. *Mathematical biosciences and engineering : MBE, 21 1*, 1305-1320. https://doi.org/10.3934/mbe.2024056

Xiao, L.-W., Mao, R., Zhao, S., Lin, Q.-K., Jia, Y.-H., He, L., & Cambria, E. (2025). Exploring Cognitive and Aesthetic Causality for Multimodal Aspect-Based Sentiment Analysis. *IEEE Transactions on Affective Computing, 16*, 3248-3265. https://doi.org/10.1109/taffc.2025.3565506

Yang, L., Na, J.-C., & Yu, J.-F. (2022). Cross-Modal Multitask Transformer for End-to-End Multimodal Aspect-Based Sentiment Analysis. *Inf. Process. Manag., 59*, 103038. https://doi.org/10.1016/j.ipm.2022.103038

Zhao, T., Meng, L.-A., & Song, D.-W. (2024). Multimodal Aspect-Based Sentiment Analysis: A survey of tasks, methods, challenges and future directions. *Inf. Fusion, 112*, 102552. https://doi.org/10.1016/j.inffus.2024.102552

Zhou, J., Zhao, J.-B., Huang, X.-J., Hu, Q., & He, L. (2021). MASAD: A large-scale dataset for multimodal aspect-based sentiment analysis. *Neurocomputing, 455*, 47-58. https://doi.org/10.1016/j.neucom.2021.05.040

Zhou, R., Guo, W., Liu, X.-M., Yu, S., Zhang, Y., & Yuan, X. (2023). AoM: Detecting Aspect-oriented Information for Multimodal Aspect-Based Sentiment Analysis. 8184-8196. https://doi.org/10.48550/arxiv.2306.01004